

**BÁO CÁO
THỰC TẬP TỐT NGHIỆP**

CÔNG TY CỔ PHẦN EHEALTH

Ngành: **Khoa Học Dữ Liệu**

Chuyên ngành: **Khoa Học Dữ Liệu**

Giảng viên hướng dẫn : ThS. Kiều Hoàng Long

Sinh viên thực hiện : Trương Minh Khoa

MSSV: 2286400011 Lớp: 22DKHA1

TP. Hồ Chí Minh, 2026

**BÁO CÁO
THỰC TẬP TỐT NGHIỆP**

CÔNG TY CỔ PHẦN EHEALTH

Ngành: **Khoa Học Dữ Liệu**

Chuyên ngành: **Khoa Học Dữ Liệu**

Giảng viên hướng dẫn : ThS. Kiều Hoàng Long

Sinh viên thực hiện : Trương Minh Khoa

MSSV: 2286400011 Lớp: 22DKHA1

TP. Hồ Chí Minh, 2026

PHIẾU NHẬN XÉT, ĐÁNH GIÁ THỰC TẬP TỐT NGHIỆP

Họ và Tên sinh viên thực tập: Trương Minh Khoa

Lớp: 22DKHA1 Ngành: Khoa Học Dữ Liệu

Niên khóa: 2022-2026

Đơn vị thực tập: CÔNG TY CỔ PHẦN EHEALTH

Thời gian thực tập: Từ 23/3/2026

đến: 17/5/2026

1. Chấp hành nội quy, quy định của cơ quan trong thời gian thực tập:

.....Tuân thủ nghiêm túc thời gian làm việc và các quy định
bảo mật của công ty.....
.....Tức phong làm việc chuyên nghiệp, tuân thủ kỷ luật.....

2. Thực hiện nhiệm vụ trong thời gian thực tập:

.....Nắm bắt nhanh, hoàn thành tất và đúng hạn các công việc
được giao.....
.....Nền tảng chuyên môn khá, tuy nhiên cần chủ động hơn
trong việc đề xuất giải pháp cho các bài toán phức tạp.....

3. Quan hệ, giao tiếp tại đơn vị thực tập:

.....Hòa đồng, giao tiếp tốt với đồng nghiệp.....
.....Kỹ năng làm việc nhóm hiệu quả, có tinh thần cầu thị
và lắng nghe.....

4. Các nhận xét khác:

.....Tư duy logic khá, thái độ học hỏi nghiêm túc. Cần rèn
luyện thêm sự tin và khả năng làm việc độc lập để phát triển tốt hơn

5. Điểm đánh giá (Theo thang điểm 10, làm tròn 0.5):8.5.....

Xác nhận của cơ quan, đơn vị thực tập

(Ký và ghi rõ họ tên và đóng dấu)



Tp.HCM, ngày 28 tháng 6 năm 2026.

Người đánh giá

(Ký và ghi rõ họ tên)

Nguyễn Quốc Bình

KHOA CÔNG NGHỆ THÔNG TIN**PHIẾU THEO DÕI TIẾN ĐỘ THỰC TẬP TỐT NGHIỆP**

1. Tên Tổ chức/Công ty (đơn vị thực tập): CÔNG TY CỔ PHẦN EHEALTH
2. Cán bộ hướng dẫn tại đơn vị thực tập (họ tên – email): Đỗ Sơn Hà - Info@ehealths.co
3. Giảng viên theo dõi/ hướng dẫn thực tập tại trường (họ tên – email): Kiều Hoàng Long - kh.long@hutech.edu.vn
4. Sinh viên thực hiện:
Họ tên: Trương Minh Khoa MSSV: 2286400011 Lớp: 22DKHA1
Ngành : Khoa Học Dữ Liệu
Chuyên ngành : Khoa Học Dữ Liệu


Tuần	Ngày	Nội dung
1	23/3/2026 - 29/3/2026	Hoàn thành quy trình nhập môn, tìm hiểu cơ cấu tổ chức và các dự án R&D đang triển khai tại doanh nghiệp. Nghiên cứu tài liệu kỹ thuật về các hệ thống hỗ trợ y tế và bước đầu tiếp cận môi trường phát triển của đội ngũ kỹ thuật.
2	30/3/2026 - 5/4/2026	Thực hiện nghiên cứu các giải pháp tối ưu hóa thuật toán cho hệ thống y tế số của công ty. Tham gia các buổi họp chuyên môn của phòng R&D để nắm bắt tiến độ dự án. Bắt đầu xây dựng thử nghiệm cho module được phân công và báo cáo kết quả khảo sát công nghệ với người hướng dẫn.
3	6/4/2026 - 12/4/2026	"Thiết kế luồng xử lý dữ liệu cho tính năng mới của ứng dụng y tế. Triển khai thử nghiệm các thuật toán cơ sở trên môi trường Sandbox của công ty. Thực hiện đánh giá sơ bộ các tham số kỹ thuật ban đầu và tối ưu hóa mã nguồn giai đoạn 1.
4	13/4/2026 - 19/4/2026	Triển khai lập trình các hàm chức năng cốt lõi cho module R&D được giao. Thực hiện viết Unit Test để kiểm thử độ ổn định của mã nguồn. Phối hợp với đội ngũ kỹ thuật của công ty cổ phần EHEALTH để khảo sát khả năng tích hợp module mới vào hệ thống backend hiện tại của công ty.

Tuần	Ngày	Nội dung
5	20/4/2026 -26/4/2026	Thực hiện kiểm thử diện rộng để so sánh hiệu năng giữa giải pháp mới nghiên cứu và các giải pháp hiện hữu tại công ty. Tổng hợp và phân tích các số liệu đạt được (độ chính xác, tốc độ xử lý). Tham gia buổi họp phản biện với Phòng R&D để tiếp nhận đánh giá và định hướng tối ưu hóa giai đoạn cuối từ Mentor.
6	27/4/2026 -3/5/2026	Tiến hành viết tài liệu kỹ thuật bao gồm hướng dẫn cài đặt, cấu trúc mã nguồn và API kết nối cho module đã phát triển. Thực hiện bàn giao phiên bản thử nghiệm ổn định (Stable Release) cho bộ phận liên quan của công ty cổ phần EHEALTH. Tham gia đánh giá kết quả thực nghiệm cuối kỳ với Hội đồng công nghệ/Mentor của phòng R&D.
7	4/5/2026 -10/5/2026	Tập trung tổng hợp toàn bộ kết quả đạt được trong suốt quá trình nghiên cứu và phát triển tại doanh nghiệp. Tiến hành viết và hoàn thiện các chương cốt lõi trong báo cáo thực tập tốt nghiệp (phần thực nghiệm và giải pháp ứng dụng). Làm việc với người hướng dẫn tại công ty cổ phần EHEALTH để rà soát lại nội dung tài liệu bàn giao kỹ thuật.
8	11/5/2026 -17/5/2026	Hoàn thiện và chuẩn hóa định dạng toàn bộ file Báo cáo thực tập tốt nghiệp. Thực hiện quy trình bàn giao sản phẩm, tài liệu kỹ thuật và tài sản cho Phòng R&D của doanh nghiệp. Xin ý kiến đánh giá, nhận xét từ người hướng dẫn và hoàn thành thủ tục ký tên, đóng dấu xác nhận thực tập tại công ty cổ phần EHEALTH.
9		
10		
11		
12		

Cán bộ hướng dẫn tại đơn vị TT
(Ký và ghi rõ họ tên)


Nguyễn Quốc Bình

TP. HCM, ngày 28 tháng 5 năm 2026
Giảng viên hướng dẫn tại trường
(Ký và ghi rõ họ tên)


Kiều Hoàng Long

LỜI CẢM ƠN

Trước hết, em xin gửi lời cảm ơn chân thành đến Ban Giám hiệu Nhà trường, Quý Thầy Cô trong Khoa và các Thầy Cô phụ trách học phần thực tập đã tạo điều kiện để em có cơ hội tham gia đợt thực tập tốt nghiệp. Trong suốt quá trình học tập tại trường, em đã được trang bị những kiến thức nền tảng về công nghệ thông tin, lập trình, trí tuệ nhân tạo và phương pháp nghiên cứu khoa học. Đây là cơ sở quan trọng giúp em có thể tiếp cận, phân tích và triển khai đề tài thực tập một cách có hệ thống.

Em xin bày tỏ lòng biết ơn sâu sắc đến giảng viên hướng dẫn đã tận tình định hướng, góp ý và hỗ trợ em trong suốt quá trình thực hiện báo cáo. Những nhận xét và hướng dẫn của Thầy/Cô không chỉ giúp em hoàn thiện nội dung chuyên môn, mà còn giúp em rèn luyện tư duy trình bày, cách tổ chức báo cáo và thái độ nghiêm túc trong nghiên cứu. Nhờ sự hướng dẫn đó, em có thêm cơ sở để nhìn nhận rõ hơn những điểm mạnh, hạn chế và hướng phát triển tiếp theo của đề tài.

Em cũng xin chân thành cảm ơn Ban lãnh đạo và các anh chị tại CÔNG TY CỔ PHẦN EHEALTH (EHEALTH JSC) đã tiếp nhận, hỗ trợ và tạo điều kiện thuận lợi cho em trong thời gian thực tập. Môi trường làm việc tại công ty đã giúp em hiểu rõ hơn cách một bài toán công nghệ được tiếp cận trong thực tế, từ việc xác định yêu cầu, chuẩn bị dữ liệu, xây dựng mô hình cho đến đánh giá kết quả. Đặc biệt, quá trình tham gia nghiên cứu bài toán ứng dụng Học sâu trong phân loại ảnh X-quang ngực đã giúp em củng cố kiến thức chuyên ngành và rèn luyện kỹ năng làm việc với dữ liệu y khoa.

Bên cạnh đó, em xin cảm ơn các anh chị hướng dẫn tại công ty đã dành thời gian trao đổi, giải đáp thắc mắc và chia sẻ kinh nghiệm thực tế trong quá trình làm việc. Những góp ý về kỹ thuật, quy trình triển khai và cách đánh giá mô hình đã giúp em có cái nhìn thực tế hơn về việc phát triển một hệ thống trí tuệ nhân tạo có khả năng ứng dụng trong lĩnh vực y tế. Đây là những kinh nghiệm quý báu mà em sẽ tiếp tục vận dụng trong học tập, nghiên cứu và công việc sau này.

Cuối cùng, em xin gửi lời cảm ơn đến gia đình, bạn bè và những người đã luôn động viên, hỗ trợ em trong suốt quá trình học tập và thực hiện báo cáo thực tập. Do thời gian thực hiện còn hạn chế và kinh nghiệm thực tế của bản thân chưa nhiều, báo cáo khó tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý của Quý Thầy Cô và các anh chị để có thể tiếp tục hoàn thiện kiến thức, kỹ năng và phát triển đề tài tốt hơn trong tương lai.

Em xin chân thành cảm ơn!

MỤC LỤC

Lời cảm ơn	vi
DANH MỤC BẢNG	ix
DANH MỤC HÌNH ẢNH	x
1 GIỚI THIỆU ĐƠN VỊ THỰC TẬP	1
1.1 Tổng quan về đơn vị thực tập	1
1.2 Môi trường làm việc và lĩnh vực chuyên môn	1
1.3 Nhiệm vụ được phân công trong đợt thực tập	2
2 NỘI DUNG CÔNG VIỆC ĐƯỢC PHÂN CÔNG	3
2.1 Bối cảnh và nhiệm vụ được giao	3
2.2 Phạm vi và mục tiêu đề tài	3
2.3 Kế hoạch thực hiện trong 8 tuần thực tập	4
2.4 Công cụ và tài nguyên sử dụng	4
3 CƠ SỞ LÝ THUYẾT	6
3.1 Mạng nơ-ron tích chập	6
3.1.1 Phép tích chập	6
3.1.2 Hàm kích hoạt ReLU và Global Average Pooling	6
3.2 Transfer Learning và Fine-tuning	7
3.3 Kiến trúc EfficientNet-B5	7
3.4 Hàm mất mát Cross-Entropy với Label Smoothing	7
3.5 Optimizer và lịch học	8
3.6 Data Augmentation, MixUp và TTA	8
3.7 Các độ đo đánh giá mô hình	9
4 PHƯƠNG PHÁP THỰC HIỆN	10
4.1 Tổng quan pipeline hệ thống	10
4.2 Thu thập và chuẩn bị dữ liệu	10
4.2.1 Nguồn dữ liệu	10
4.2.2 Quy trình xử lý dữ liệu	10
4.3 Tiền xử lý ảnh và tăng cường dữ liệu	11
4.4 Kiến trúc và cài đặt mô hình	12
4.5 Chiến lược huấn luyện	13
4.6 Đánh giá và minh họa triển khai	13

5	KẾT QUẢ VÀ ĐÁNH GIÁ	14
5.1	Kết quả huấn luyện	14
5.2	Kết quả chi tiết theo từng lớp bệnh	14
5.3	Ma trận nhầm lẫn	15
5.4	So sánh với các nghiên cứu liên quan	17
6	KẾT QUẢ ĐẠT ĐƯỢC QUA ĐỢT THỰC TẬP	18
6.1	Kiến thức lý thuyết đã được củng cố	18
6.2	Kỹ năng thực hành đã học hỏi được	18
6.3	Sản phẩm và đóng góp cho đơn vị thực tập	18
6.4	Bài học kinh nghiệm	19
7	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	20
7.1	Kết luận	20
7.2	Hạn chế	20
7.3	Hướng phát triển	20

DANH MỤC BẢNG

1	Các nhãn phân loại trong đề tài	3
2	Kế hoạch thực hiện trong 8 tuần thực tập	4
3	Phân phối dữ liệu sau cân bằng	11
4	Các kỹ thuật augmentation sử dụng trong tập train	12
5	Classification report trên tập kiểm định	15
6	So sánh với một số nghiên cứu liên quan	17

DANH MỤC HÌNH ẢNH

1	Đường cong loss và accuracy trong quá trình huấn luyện	14
2	Ma trận nhầm lẫn theo số lượng mẫu trên tập kiểm định	16
3	Ma trận nhầm lẫn theo tỷ lệ phần trăm trên tập kiểm định	16

CHƯƠNG 1. GIỚI THIỆU ĐƠN VỊ THỰC TẬP

1.1 Tổng quan về đơn vị thực tập

CÔNG TY CỔ PHẦN EHEALTH, tên quốc tế là EHEALTH JOINT STOCK COMPANY và tên viết tắt là EHEALTH JSC, là doanh nghiệp hoạt động theo loại hình công ty cổ phần. Theo thông tin đăng ký doanh nghiệp công khai, công ty có mã số thuế 0318761246, bắt đầu hoạt động từ ngày 25/11/2024, người đại diện theo pháp luật là ông Nguyễn Quốc Bình và trụ sở đặt tại 29 Tân Thành, Phường Hoà Thạnh, Quận Tân Phú, Thành phố Hồ Chí Minh [1]. Ngành nghề chính được đăng ký là xuất bản phần mềm, phù hợp với định hướng phát triển các sản phẩm và dịch vụ công nghệ thông tin trong lĩnh vực y tế số.

Trong quá trình thực tập, sinh viên được tiếp cận môi trường làm việc của EHEALTH JSC với định hướng phát triển các giải pháp phần mềm hỗ trợ hoạt động y tế. Một trong những hệ thống được đề cập trong quá trình thực tập là hệ thống Diamond, đóng vai trò nền tảng nghiệp vụ để công ty nghiên cứu khả năng tích hợp thêm các module xử lý dữ liệu và hỗ trợ ra quyết định. Trong bối cảnh y tế số hiện nay, việc ứng dụng Trí tuệ Nhân tạo (AI) vào các quy trình phân tích dữ liệu lâm sàng và hỗ trợ chẩn đoán là một hướng phát triển có nhiều tiềm năng [2].

1.2 Môi trường làm việc và lĩnh vực chuyên môn

Môi trường làm việc tại công ty có tính linh hoạt, đặc biệt đối với các nhiệm vụ nghiên cứu và phát triển. Sinh viên thực tập được định hướng tiếp cận bài toán theo quy trình gồm phân tích yêu cầu, chuẩn bị dữ liệu, xây dựng mô hình, thử nghiệm và đánh giá kết quả. Cách tổ chức này giúp quá trình thực tập gắn với nhu cầu ứng dụng thực tế thay vì chỉ dừng lại ở mức thử nghiệm lý thuyết.

Lĩnh vực chuyên môn trọng tâm trong đợt thực tập là khai thác Học sâu (Deep Learning) cho bài toán xử lý ảnh y khoa. Đây là hướng nghiên cứu quan trọng vì các mô hình học sâu có khả năng tự động trích xuất đặc trưng từ ảnh, hỗ trợ nhận diện các mẫu hình bệnh lý phức tạp và giảm bớt khối lượng phân tích thủ công trong chẩn đoán hình ảnh [3]. Đối với ảnh X-quang ngực, các kỹ thuật học sâu thường được sử dụng để phân loại hoặc sàng lọc các bất thường liên quan đến phổi, từ đó cung cấp thêm thông tin tham khảo cho quy trình chuyên môn.

Về cơ sở hạ tầng, môi trường phát triển được thiết lập với các công cụ phù hợp cho bài toán Học sâu như PyTorch và thư viện timm. Bên cạnh đó, tài nguyên điện toán đám mây sử dụng GPU T4 (16 GB VRAM) được tận dụng để tăng tốc quá trình huấn luyện và thử nghiệm mô hình. Việc lựa chọn hạ tầng tính toán phù hợp có ý nghĩa quan trọng đối với các bài toán xử lý ảnh y khoa, vốn thường yêu cầu dữ liệu lớn, mô hình phức tạp và nhiều vòng thử nghiệm.

1.3 Nhiệm vụ được phân công trong đợt thực tập

Dưới sự hướng dẫn của bộ phận phụ trách nghiên cứu và phát triển, nhiệm vụ chính trong đợt thực tập là nghiên cứu và xây dựng hệ thống AI hỗ trợ phân loại ảnh X-quang ngực. Nhiệm vụ này gắn với xu hướng ứng dụng học sâu trong phân tích ảnh y khoa và hỗ trợ bác sĩ trong quá trình sàng lọc, phân loại bệnh lý [2, 3].

Cụ thể, các nội dung công việc bao gồm:

- **Chuẩn bị dữ liệu:** Thu thập, làm sạch và thực hiện các kỹ thuật tiền xử lý trên tập dữ liệu ảnh X-quang ngực. Các bước xử lý bao gồm chuẩn hóa dữ liệu, cân bằng lớp và tăng cường dữ liệu (Data Augmentation) nhằm giảm ảnh hưởng của hiện tượng mất cân bằng dữ liệu trong quá trình huấn luyện [4].
- **Nghiên cứu và thử nghiệm mô hình:** Lựa chọn, huấn luyện và tinh chỉnh các kiến trúc mạng nơ-ron tích chập (CNN). Trọng tâm của nhiệm vụ là áp dụng Transfer Learning với kiến trúc EfficientNet-B5 để giải quyết bài toán phân loại đa lớp trên ảnh X-quang ngực [5, 6].
- **Xây dựng module phân loại:** Hoàn thiện module phần mềm có khả năng nhận diện và phân loại các nhóm bệnh lý phổi từ ảnh X-quang ngực. Module này được thiết kế theo hướng có thể tiếp tục đánh giá, cải tiến và tích hợp vào hệ thống Diamond khi đáp ứng đủ yêu cầu thực tế.
- **Đánh giá mô hình:** Đo lường hiệu năng của mô hình thông qua các chỉ số như Accuracy, Precision, Recall và F1-score. Kết quả đánh giá là cơ sở để xem xét tính khả thi của việc triển khai module AI trong môi trường ứng dụng thực tế.

CHƯƠNG 2. NỘI DUNG CÔNG VIỆC ĐƯỢC PHÂN CÔNG

2.1 Bối cảnh và nhiệm vụ được giao

Trong khuôn khổ đợt thực tập tốt nghiệp tại bộ phận R&D của CÔNG TY CỔ PHẦN EHEALTH, sinh viên được giao thực hiện đề tài “*Xây dựng hệ thống hỗ trợ chẩn đoán bệnh phổi trên ảnh X-quang ngực bằng mạng nơ-ron tích chập (CNN)*”. Đây là đề tài nghiên cứu–thực hành có tính ứng dụng, phù hợp với định hướng phát triển các module trí tuệ nhân tạo có khả năng hỗ trợ hệ thống y khoa Diamond trong tương lai.

Nhiệm vụ không chỉ dừng ở việc thử nghiệm mô hình phân loại ảnh, mà còn yêu cầu sinh viên tiếp cận toàn bộ quy trình phát triển một module AI: khảo sát dữ liệu, chuẩn hóa dữ liệu, huấn luyện mô hình, đánh giá kết quả, phân tích lỗi và xây dựng bản minh họa triển khai. Cách tiếp cận này giúp quá trình thực tập gắn với yêu cầu thực tế của doanh nghiệp, đồng thời tạo điều kiện để sinh viên vận dụng kiến thức về học sâu, xử lý ảnh và phát triển phần mềm.

2.2 Phạm vi và mục tiêu đề tài

Mục tiêu chính của đề tài là xây dựng một mô hình học sâu có khả năng phân loại ảnh X-quang ngực thành 5 nhóm: COVID-19, Fibrosis, Lung Opacity, Normal và Viral Pneumonia. Mô hình được kỳ vọng đạt độ chính xác tối thiểu 85% trên tập kiểm định, đồng thời được đánh giá bằng các chỉ số phù hợp với bài toán y tế như Accuracy, Precision, Recall, F1-score và Confusion Matrix.

Bên cạnh phần mô hình, đề tài còn hướng đến việc xây dựng một pipeline có khả năng tái sử dụng. Pipeline này bao gồm các bước tiền xử lý ảnh, tăng cường dữ liệu, huấn luyện EfficientNet-B5, đánh giá với Test-Time Augmentation (TTA) và chuẩn bị hướng tích hợp vào backend FastAPI cùng giao diện Flutter Web. Bảng 1 trình bày các nhãn phân loại được sử dụng trong đề tài.

Bảng 1: Các nhãn phân loại trong đề tài

Nhãn	Mô tả lâm sàng
COVID-19	Viêm phổi do virus SARS-CoV-2
Fibrosis	Xơ phổi, hình thành sẹo hoặc tổn thương mô phổi
Lung Opacity	Mờ phổi hoặc vùng tổn thương bất thường trên ảnh X-quang
Normal	Phổi bình thường, không ghi nhận dấu hiệu bệnh lý rõ ràng
Viral Pneumonia	Viêm phổi do virus thông thường

2.3 Kế hoạch thực hiện trong 8 tuần thực tập

Quá trình thực tập được chia thành 8 tuần, tương ứng với các giai đoạn từ khảo sát lý thuyết đến hoàn thiện báo cáo và bàn giao sản phẩm. Kế hoạch này giúp sinh viên kiểm soát tiến độ, đồng thời bảo đảm các bước quan trọng của một bài toán học máy được thực hiện đầy đủ.

Bảng 2: Kế hoạch thực hiện trong 8 tuần thực tập

Tuần	Nội dung công việc
Tuần 1	Tìm hiểu cơ sở lý thuyết về Deep Learning, CNN, Transfer Learning và EfficientNet; nghiên cứu bài toán phân loại ảnh X-quang phổi; cài đặt môi trường Python, PyTorch, timm và Kaggle GPU.
Tuần 2	Khảo sát hai bộ dữ liệu trên Kaggle gồm COVID-19 Radiography Database và VinBigData Chest X-ray; phân tích phân phối dữ liệu và xác định vấn đề mất cân bằng lớp.
Tuần 3	Xây dựng pipeline xử lý dữ liệu gồm lọc nhãn, chuẩn hóa nhãn, gộp hai nguồn dữ liệu và cân bằng số lượng mẫu ở từng lớp.
Tuần 4	Thiết kế pipeline tiền xử lý ảnh và Data Augmentation; cài đặt MixUp, RandomErasing, ColorJitter, lớp Dataset và DataLoader.
Tuần 5	Thử nghiệm mô hình EfficientNet-B5; cài đặt AdamW, Differential Learning Rate và Learning Rate Scheduler; xử lý lỗi OOM, NaN loss trên GPU T4.
Tuần 6	Huấn luyện chính thức với AMP, Label Smoothing, Early Stopping và Gradient Clipping; theo dõi training curves và điều chỉnh hyperparameters.
Tuần 7	Đánh giá mô hình tốt nhất bằng $TTA \times 5$; vẽ Confusion Matrix, xuất classification report, phân tích kết quả theo từng lớp; xây dựng bản minh họa backend và giao diện.
Tuần 8	Hoàn thiện báo cáo thực tập, chuẩn bị bài thuyết trình bảo vệ và bàn giao mã nguồn, kết quả thực nghiệm cho đơn vị thực tập.

2.4 Công cụ và tài nguyên sử dụng

Các công cụ chính được sử dụng trong đề tài gồm Python 3.9+, PyTorch 2.x và thư viện timm cho phần huấn luyện mô hình. Đối với phần minh họa triển khai, backend được định hướng xây dựng bằng FastAPI và Uvicorn, trong khi giao diện người dùng sử dụng Flutter Web. Tài nguyên tính toán chủ yếu là Kaggle Notebook với GPU NVIDIA T4 16 GB VRAM, phù hợp để huấn luyện mô hình EfficientNet-B5 ở kích thước ảnh 256×256.

Dữ liệu được thu thập từ các bộ dữ liệu công khai trên Kaggle, bao gồm COVID-19 Radiography Database và VinBigData Chest X-ray. Việc sử dụng hai nguồn dữ liệu giúp đề tài có đủ các lớp bệnh cần phân loại, đặc biệt là lớp Fibrosis vốn không xuất hiện trong bộ COVID-19 Radiography. Mã nguồn được quản lý bằng Git nhằm theo dõi thay đổi và hỗ trợ quá trình bàn giao.

CHƯƠNG 3. CƠ SỞ LÝ THUYẾT

3.1 Mạng nơ-ron tích chập

Mạng nơ-ron tích chập (Convolutional Neural Network – CNN) là kiến trúc nền tảng trong xử lý ảnh y khoa nhờ khả năng học đặc trưng trực tiếp từ dữ liệu ảnh. Khác với các phương pháp xử lý ảnh thủ công, CNN tự động học các đặc trưng theo nhiều cấp độ: từ cạnh, góc, texture ở các lớp nông đến cấu trúc tổn thương phức tạp ở các lớp sâu hơn. Khả năng này đặc biệt phù hợp với ảnh X-quang ngược, nơi các dấu hiệu bệnh lý có thể phân bố mờ, không đồng nhất và khó mô tả bằng quy tắc cố định [3].

3.1.1 Phép tích chập

Cho ảnh đầu vào $I \in \mathbb{R}^{H \times W \times C}$ và bộ lọc $K \in \mathbb{R}^{k \times k \times C}$, đầu ra tại vị trí (i, j) được tính theo công thức:

$$(I * K)(i, j) = \sum_{c=1}^C \sum_{m=1}^k \sum_{n=1}^k I(i+m, j+n, c) K(m, n, c). \quad (1)$$

Trong đó H, W là chiều cao và chiều rộng ảnh, C là số kênh đầu vào, còn k là kích thước kernel. Phép tích chập giúp mô hình học các đặc trưng cục bộ và chia sẻ trọng số trên toàn ảnh, từ đó giảm số tham số so với mạng fully-connected truyền thống.

3.1.2 Hàm kích hoạt ReLU và Global Average Pooling

Sau phép tích chập, mô hình thường sử dụng hàm kích hoạt ReLU để đưa tính phi tuyến vào mạng:

$$\text{ReLU}(x) = \max(0, x). \quad (2)$$

ReLU giúp giảm hiện tượng vanishing gradient và có chi phí tính toán thấp. Ở phần cuối mạng, EfficientNet sử dụng Global Average Pooling (GAP) để đưa tensor đặc trưng về vector trước khi phân loại. Với tensor $X \in \mathbb{R}^{H \times W \times C}$, giá trị GAP tại kênh c được tính:

$$\text{GAP}(c) = \frac{1}{HW} \sum_{h=1}^H \sum_{w=1}^W X(h, w, c). \quad (3)$$

GAP giúp giảm số tham số, hạn chế overfitting và giữ lại thông tin tổng quát của từng kênh đặc trưng.

3.2 Transfer Learning và Fine-tuning

Transfer Learning là kỹ thuật tận dụng trọng số đã học từ một tác vụ nguồn để giải quyết tác vụ đích. Trong đề tài này, mô hình EfficientNet-B5 được khởi tạo bằng trọng số pretrained trên ImageNet, sau đó fine-tuning trên tập ảnh X-quang ngực 5 lớp. Cách tiếp cận này phù hợp với bài toán y tế vì dữ liệu gán nhãn thường ít hơn nhiều so với dữ liệu ảnh tự nhiên quy mô lớn [7].

Nếu ký hiệu w_{ImageNet}^* là trọng số đã học từ ImageNet, quá trình khởi tạo mô hình có thể biểu diễn như sau:

$$w_{\text{init}} = w_{\text{ImageNet}}^*. \quad (4)$$

Sau khi khởi tạo, toàn bộ mô hình được cập nhật với learning rate nhỏ để vừa giữ lại các đặc trưng tổng quát như cạnh, góc, texture, vừa thích nghi với đặc trưng bệnh lý trong ảnh X-quang. Trong thực nghiệm, backbone sử dụng learning rate thấp hơn head phân loại mới nhằm tránh phá vỡ trọng số pretrained.

3.3 Kiến trúc EfficientNet-B5

EfficientNet là họ kiến trúc CNN được đề xuất bởi Tan và Le, nổi bật nhờ nguyên lý Compound Scaling [5]. Thay vì chỉ tăng chiều sâu hoặc chiều rộng, EfficientNet mở rộng đồng thời ba thành phần: depth, width và resolution theo một hệ số tổng hợp ϕ :

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi, \quad (5)$$

với ràng buộc:

$$\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2, \quad \alpha \geq 1, \beta \geq 1, \gamma \geq 1. \quad (6)$$

Phiên bản EfficientNet-B5 có khoảng 30 triệu tham số, sử dụng các khối MBConv kết hợp Squeeze-and-Excitation, đạt độ chính xác cao trên ImageNet trong khi vẫn phù hợp với tài nguyên GPU T4 khi ảnh được resize về 256×256. So với các kiến trúc cũ như VGG-16 hoặc ResNet-50, EfficientNet-B5 đem lại sự cân bằng tốt hơn giữa năng lực biểu diễn và chi phí tính toán. Các nghiên cứu trước đây cũng cho thấy EfficientNet có tiềm năng trong bài toán phân tích ảnh y khoa [6].

3.4 Hàm mất mát Cross-Entropy với Label Smoothing

Đối với bài toán phân loại đa lớp, Cross-Entropy Loss được sử dụng để đo sai khác giữa phân phối nhãn thật và phân phối xác suất dự đoán. Với K lớp, nhãn thật y và xác suất dự đoán p , hàm mất mát chuẩn được tính:

$$L_{CE} = - \sum_{k=1}^K y_k \log(p_k), \quad (7)$$

trong đó p_k là xác suất sau Softmax:

$$p_k = \frac{\exp(z_k)}{\sum_{j=1}^K \exp(z_j)}. \quad (8)$$

Để giảm hiện tượng mô hình quá tự tin, đề tài sử dụng Label Smoothing với $\varepsilon = 0.1$. Nhân cứng được chuyển thành nhân mềm:

$$y_k^{smooth} = (1 - \varepsilon)y_k + \frac{\varepsilon}{K}. \quad (9)$$

Khi $K = 5$ và $\varepsilon = 0.1$, lớp đúng có giá trị xấp xỉ 0.9, các lớp còn lại nhận một phần xác suất nhỏ. Kỹ thuật này giúp mô hình tổng quát tốt hơn trên tập kiểm định.

3.5 Optimizer và lịch học

Đề tài sử dụng AdamW, một biến thể của Adam tách riêng weight decay khỏi gradient update. Với gradient g_t , moment bậc nhất m_t và moment bậc hai v_t , quá trình cập nhật có dạng tổng quát:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (10)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2. \quad (11)$$

Sau khi hiệu chỉnh bias, tham số được cập nhật kèm weight decay:

$$\theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} - \eta \lambda \theta_{t-1}. \quad (12)$$

Trong thực nghiệm, backbone EfficientNet dùng learning rate 1×10^{-4} , còn classifier head dùng 3×10^{-4} . Lịch học gồm giai đoạn warmup ở các epoch đầu và Cosine Annealing ở giai đoạn sau, giúp mô hình hội tụ ổn định hơn.

3.6 Data Augmentation, MixUp và TTA

Data Augmentation được sử dụng để tăng tính đa dạng dữ liệu huấn luyện. Các phép biến đổi gồm RandomHorizontalFlip, RandomRotation, ColorJitter, RandomGrayscale và RandomErasing. Những kỹ thuật này mô phỏng sai khác do tư thế chụp, thiết bị chụp

và chất lượng ảnh giữa các cơ sở y tế.

Bên cạnh đó, MixUp tạo mẫu huấn luyện mới bằng cách nội suy hai ảnh và hai nhãn tương ứng [8]:

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j, \quad (13)$$

$$\tilde{y} = \lambda y_i + (1 - \lambda)y_j, \quad (14)$$

với $\lambda \sim \text{Beta}(\alpha, \alpha)$ và $\alpha = 0.4$. MixUp buộc mô hình học ranh giới quyết định mềm hơn, qua đó giảm overfitting.

Ở giai đoạn đánh giá, Test-Time Augmentation (TTA×5) được dùng để dự đoán trung bình trên 5 biến thể của cùng một ảnh. Xác suất cuối cùng được tính:

$$p_{avg} = \frac{1}{5} \sum_{i=1}^5 \text{softmax}(f(TTA_i(x))). \quad (15)$$

TTA giúp cải thiện độ ổn định dự đoán mà không cần huấn luyện lại mô hình.

3.7 Các độ đo đánh giá mô hình

Với từng lớp k , các chỉ số Precision, Recall và F1-score được tính như sau:

$$Precision_k = \frac{TP_k}{TP_k + FP_k}, \quad Recall_k = \frac{TP_k}{TP_k + FN_k}. \quad (16)$$

$$F1_k = \frac{2 \cdot Precision_k \cdot Recall_k}{Precision_k + Recall_k}. \quad (17)$$

Accuracy toàn bộ được tính theo tỷ lệ số mẫu dự đoán đúng trên tổng số mẫu:

$$Accuracy = \frac{\sum_k TP_k}{N}. \quad (18)$$

Trong bài toán y tế, F1-score và Confusion Matrix đặc biệt quan trọng vì chúng cho thấy mô hình có đang bỏ sót lớp bệnh hay nhầm lẫn giữa các bệnh có biểu hiện hình ảnh tương tự hay không.

CHƯƠNG 4. PHƯƠNG PHÁP THỰC HIỆN

4.1 Tổng quan pipeline hệ thống

Pipeline thực hiện đề tài được thiết kế theo hướng end-to-end, bắt đầu từ dữ liệu thô và kết thúc ở mô hình có thể đánh giá, lưu checkpoint và minh họa triển khai. Luồng xử lý tổng quát gồm các bước: thu thập dữ liệu, lọc và gộp dữ liệu, cân bằng lớp, tiền xử lý và tăng cường dữ liệu, huấn luyện EfficientNet-B5, đánh giá bằng TTA×5, sau đó chuẩn bị backend API và giao diện minh họa.

Cách tổ chức pipeline theo từng bước giúp quá trình thực nghiệm dễ kiểm soát. Khi kết quả không đạt kỳ vọng, sinh viên có thể truy ngược về từng giai đoạn như phân phối dữ liệu, augmentation, learning rate hoặc tiêu chí dừng sớm để điều chỉnh thay vì thay đổi toàn bộ hệ thống.

4.2 Thu thập và chuẩn bị dữ liệu

4.2.1 Nguồn dữ liệu

Đề tài sử dụng hai nguồn dữ liệu công khai. Nguồn thứ nhất là COVID-19 Radiography Database, gồm ảnh X-quang ngực định dạng PNG với các lớp COVID, Normal, Lung Opacity và Viral Pneumonia [9]. Nguồn thứ hai là VinBigData Chest X-ray, gồm ảnh X-quang ngực với nhiều nhãn bệnh lý; trong đề tài chỉ sử dụng các nhãn Normal, Fibrosis và Lung Opacity.

Việc kết hợp hai nguồn dữ liệu có ý nghĩa quan trọng vì bộ COVID-19 Radiography không có lớp Fibrosis. Trong khi đó, Fibrosis là một lớp bệnh cần phân loại và có đặc trưng hình ảnh dễ nhầm với Lung Opacity. Kết hợp dữ liệu giúp bài toán đủ 5 lớp, đồng thời tăng tính đa dạng về nguồn ảnh và thiết bị chụp.

4.2.2 Quy trình xử lý dữ liệu

Quy trình chuẩn bị dữ liệu gồm ba bước chính. Bước thứ nhất là lọc dữ liệu VinBigData bằng các script như `filter_img.py` và `select_ID.py`. Các nhãn không liên quan được loại bỏ, nhãn được chuẩn hóa về cùng cách đặt tên, ví dụ *No finding* được chuyển thành *Normal* và *Pulmonary fibrosis* được chuyển thành *Fibrosis*.

Bước thứ hai là gộp dữ liệu từ hai nguồn bằng `merge_data.py`. Sau khi gộp, dữ liệu được thống nhất về cấu trúc gồm đường dẫn ảnh và tên lớp. Bước thứ ba là cân bằng dữ liệu bằng undersampling, giới hạn tối đa 1.500 ảnh cho mỗi lớp. Phương pháp này được ưu tiên hơn oversampling vì ảnh y tế có cấu trúc phức tạp; việc nhân bản hoặc nội suy ảnh có thể tạo ra mẫu thiếu thực tế và làm sai lệch đặc trưng bệnh lý.

Bảng 3: Phân phối dữ liệu sau cân bằng

Lớp	Số mẫu gốc	Sau cân bằng	Validation
COVID	3.616	1.500	300
Fibrosis	1.617	1.500	300
Lung_Opacity	7.334	1.500	300
Normal	9.000	1.500	300
Viral Pneumonia	1.345	1.345	269
Tổng	22.912	7.345	1.469

4.3 Tiền xử lý ảnh và tăng cường dữ liệu

Tất cả ảnh đầu vào được chuyển về RGB để thống nhất số kênh, kể cả trường hợp ảnh gốc là grayscale hoặc được chuyển đổi từ DICOM. Ở tập huấn luyện, ảnh được resize về 288×288 rồi RandomCrop về 256×256. Ở tập validation, ảnh được resize trực tiếp về 256×256. Kích thước 256 được lựa chọn thay vì 456 như cấu hình gốc EfficientNet-B5 nhằm phù hợp giới hạn VRAM 16 GB của GPU T4 và cho phép sử dụng batch size lớn hơn.

Ảnh sau đó được chuẩn hóa theo mean và std của ImageNet: mean = [0.485, 0.456, 0.406], std = [0.229, 0.224, 0.225]. Việc chuẩn hóa theo ImageNet là cần thiết vì mô hình backbone được khởi tạo bằng pretrained weights trên ImageNet.

Việc chọn kích thước 256×256 là một thỏa hiệp giữa khả năng giữ lại đặc trưng bệnh lý và chi phí tính toán. Ảnh gốc từ VinBigData và COVID-19 Radiography đều có độ phân giải lớn hơn kích thước huấn luyện, do đó bước resize chủ yếu là thu nhỏ ảnh thay vì phóng to ảnh. Cách xử lý này hạn chế việc tạo thêm nhiễu nội suy và vẫn giữ được hình thái tổng quát của phổi.

Các dấu hiệu như vùng mờ phổi, tổn thương dạng ground-glass opacity hoặc thay đổi mô xơ thường là đặc trưng cấp vùng, phân bố trên diện tích tương đối rộng của ảnh X-quang. Vì vậy, kích thước 256×256 vẫn đủ để CNN học các mẫu hình quan trọng phục vụ phân loại. Trong các nghiên cứu về phân tích ảnh X-quang ngực, kích thước đầu vào khoảng 224×224 cũng thường được sử dụng khi huấn luyện mô hình CNN trên ảnh y khoa [10].

Nếu sử dụng kích thước gốc 456×456 của EfficientNet-B5, chi phí bộ nhớ tăng đáng kể vì kích thước tensor đặc trưng phụ thuộc trực tiếp vào diện tích ảnh. Với GPU NVIDIA T4 16 GB VRAM, cấu hình 256×256 giúp duy trì batch size 32, giảm nguy cơ lỗi OOM và rút ngắn thời gian mỗi lần thử nghiệm. Để bù lại phần thông tin có thể mất do resize, đề tài dùng RandomCrop từ ảnh 288×288 trong giai đoạn train và TTA×5 ở giai đoạn inference, giúp mô hình quan sát nhiều biến thể không gian của cùng một ảnh.

Bảng 4: Các kỹ thuật augmentation sử dụng trong tập train

Kỹ thuật	Tham số
RandomHorizontalFlip	$p = 0.5$
RandomVerticalFlip	$p = 0.1$
RandomRotation	$\pm 20^\circ$
ColorJitter	brightness=0.3, contrast=0.3
RandomGrayscale	$p = 0.05$
RandomErasing	$p = 0.2$, scale=(0.02–0.12)
MixUp	$\alpha = 0.4$, áp dụng khoảng 50% batch

4.4 Kiến trúc và cài đặt mô hình

Mô hình chính sử dụng EfficientNet-B5 từ thư viện timm, khởi tạo với trọng số pretrained trên ImageNet. Lớp classifier cuối được thay bằng lớp tuyến tính mới để ánh xạ vector đặc trưng sang 5 lớp bệnh. Toàn bộ backbone được fine-tuning ngay từ epoch đầu, nhưng dùng learning rate nhỏ hơn so với classifier head.

Việc chọn EfficientNet-B5 dựa trên sự cân bằng giữa độ chính xác và tài nguyên tính toán. Các phiên bản B0–B4 nhẹ hơn nhưng có năng lực biểu diễn thấp hơn, trong khi B6–B7 yêu cầu nhiều VRAM hơn, khó huấn luyện ổn định trên GPU T4 với batch size 32. B5 là lựa chọn phù hợp để đạt hiệu năng tốt mà vẫn kiểm soát được chi phí tính toán.

Bản chất bài toán trong đề tài là phân loại ảnh ở mức toàn ảnh. Với mỗi ảnh X-quang đầu vào, hệ thống cần dự đoán một trong 5 nhãn bệnh: COVID-19, Fibrosis, Lung Opacity, Normal hoặc Viral Pneumonia. Dữ liệu sử dụng chỉ cung cấp nhãn lớp cho toàn ảnh, không có bounding box hoặc mask phân đoạn vùng tổn thương. Vì vậy, kiến trúc classification như EfficientNet phù hợp trực tiếp với cấu trúc dữ liệu và mục tiêu đánh giá của đề tài.

YOLO là họ mô hình phục vụ object detection, thường yêu cầu dữ liệu huấn luyện có tọa độ bounding box của từng đối tượng. Nếu áp dụng YOLO cho bài toán hiện tại, cần bổ sung annotation vị trí tổn thương trên phổi, trong khi hai bộ dữ liệu được sử dụng không cung cấp đầy đủ loại nhãn này. Ngoài ra, nhiều bệnh lý trong ảnh X-quang như mờ phổi, xơ hóa hoặc viêm phổi có biểu hiện lan tỏa, không phải vật thể có ranh giới rõ như trong bài toán phát hiện đối tượng thông thường. Do đó, việc ép bài toán sang object detection có thể làm tăng chi phí gán nhãn và độ phức tạp mà không trực tiếp phục vụ mục tiêu phân loại 5 lớp.

EfficientNet vẫn là lựa chọn phù hợp cho đề tài vì kiến trúc này được thiết kế để mở rộng đồng thời depth, width và resolution theo nguyên lý Compound Scaling [5]. Nhờ đó, mô hình đạt khả năng biểu diễn mạnh nhưng vẫn tiết kiệm FLOPs hơn nhiều kiến trúc CNN truyền thống. Trong bối cảnh thực nghiệm trên GPU T4, EfficientNet-B5 cho

phép tận dụng transfer learning, fine-tuning toàn bộ backbone và kết hợp các kỹ thuật như AMP, MixUp, Label Smoothing và TTA mà vẫn giữ được quy trình huấn luyện khả thi. Các nghiên cứu trước cũng cho thấy EfficientNet có hiệu quả trong nhiều bài toán ảnh y khoa [6].

4.5 Chiến lược huấn luyện

Quá trình huấn luyện sử dụng AdamW với weight decay 10^{-4} , Label Smoothing $\varepsilon = 0.1$, Differential Learning Rate và lịch học Warmup kết hợp Cosine Annealing. Mô hình được huấn luyện với Mixed Precision Training (AMP) nhằm giảm VRAM và tăng tốc tính toán trên GPU có Tensor Core.

Để hạn chế lỗi gradient explosion, đề tài sử dụng Gradient Clipping với ngưỡng max norm bằng 1.0:

$$g_{clipped} = g \cdot \min \left(1, \frac{1.0}{\|g\|_2} \right). \quad (19)$$

Early Stopping được áp dụng dựa trên validation loss hoặc validation F1-score để tránh overfitting. Checkpoint tốt nhất được lưu lại và sử dụng cho giai đoạn đánh giá cuối cùng.

4.6 Đánh giá và minh họa triển khai


Sau khi huấn luyện, mô hình tốt nhất được đánh giá bằng TTA×5. Kết quả được tổng hợp thông qua classification report và confusion matrix. Các chỉ số Precision, Recall và F1-score được phân tích theo từng lớp nhằm nhận diện các cặp nhãn dễ nhầm lẫn như Fibrosis và Lung Opacity.

Đối với phần minh họa ứng dụng, mô hình được định hướng đóng gói để phục vụ backend FastAPI. Backend nhận ảnh X-quang từ người dùng, thực hiện tiền xử lý tương tự giai đoạn validation, chạy suy luận và trả về nhãn dự đoán cùng xác suất. Giao diện Flutter Web đóng vai trò minh họa quy trình sử dụng, cho phép tải ảnh và hiển thị kết quả dự đoán một cách trực quan.

CHƯƠNG 5. KẾT QUẢ VÀ ĐÁNH GIÁ

5.1 Kết quả huấn luyện

Quá trình huấn luyện được theo dõi thông qua đường cong loss và accuracy trên tập train và validation. Hình 1 cho thấy train loss giảm nhanh trong các epoch đầu, sau đó giảm chậm hơn khi mô hình tiến dần đến trạng thái hội tụ. Validation loss có xu hướng bám sát train loss, không xuất hiện hiện tượng tăng mạnh kéo dài, cho thấy các kỹ thuật như augmentation, Label Smoothing, MixUp, AdamW và Early Stopping đã hỗ trợ kiểm soát overfitting.



Hình 1: Đường cong loss và accuracy trong quá trình huấn luyện

Với mô hình tốt nhất, validation accuracy đạt 91.76% khi sử dụng TTA×5. Kết quả này vượt mục tiêu tối thiểu 85% đặt ra ban đầu, đồng thời cho thấy EfficientNet-B5 có khả năng học được các đặc trưng phân biệt giữa những nhóm bệnh phổi trên ảnh X-quang.

5.2 Kết quả chi tiết theo từng lớp bệnh

Bảng 5 trình bày classification report trên tập kiểm định gồm 1.469 ảnh. Ngoài Accuracy tổng thể, các chỉ số Precision, Recall và F1-score theo từng lớp được sử dụng để đánh giá chi tiết hơn hành vi của mô hình.


Bảng 5: Classification report trên tập kiểm định

Lớp	Precision	Recall	F1-score	Support
COVID	0.9698	0.9633	0.9666	300
Fibrosis	0.8750	0.8867	0.8808	300
Lung_Opacity	0.9321	0.8233	0.8743	300
Normal	0.8429	0.9300	0.8843	300
Viral Pneumonia	0.9852	0.9926	0.9889	269
Macro avg	0.9210	0.9192	0.9190	1469
Weighted avg	0.9196	0.9176	0.9175	1469
Accuracy		0.9176		1469


Lớp Viral Pneumonia đạt F1-score cao nhất, cho thấy mô hình nhận diện tốt các đặc trưng hình ảnh của nhóm này. Lớp COVID cũng đạt F1-score cao nhờ các đặc trưng như ground-glass opacity tương đối rõ. Ngược lại, Fibrosis và Lung_Opacity có F1-score thấp hơn do hai nhóm này có texture và vùng mờ phổi tương đồng, dễ gây nhầm lẫn ngay cả trong phân tích lâm sàng.

5.3 Ma trận nhầm lẫn

Ma trận nhầm lẫn ở Hình 2 và Hình 3 cho phép quan sát trực tiếp các cặp lớp dễ nhầm theo số lượng mẫu và theo tỷ lệ phần trăm. Các sai số đáng chú ý tập trung ở Fibrosis và Lung_Opacity, cũng như một phần Lung_Opacity bị dự đoán thành Normal khi tổn thương không rõ ràng.



Hình 2: Ma trận nhầm lẫn theo số lượng mẫu trên tập kiểm định



Hình 3: Ma trận nhầm lẫn theo tỷ lệ phần trăm trên tập kiểm định

Từ góc nhìn y khoa, những nhầm lẫn này có thể giải thích được. Fibrosis thường thể hiện qua các vùng xơ hóa hoặc thay đổi cấu trúc mô phổi, trong khi Lung Opacity cũng tạo ra vùng mờ bất thường trên ảnh. Khi ảnh có chất lượng thấp hoặc tổn thương nhẹ,

ranh giới giữa hai nhóm này không rõ ràng, làm tăng khả năng mô hình dự đoán sai.

5.4 So sánh với các nghiên cứu liên quan

Bảng 6 so sánh kết quả của đề tài với một số nghiên cứu liên quan. Cần lưu ý rằng nhiều nghiên cứu trước chỉ xử lý bài toán 2 hoặc 3 lớp, trong khi đề tài này phân loại 5 lớp nên độ khó cao hơn.

Bảng 6: So sánh với một số nghiên cứu liên quan

Nghiên cứu	Mô hình	Dữ liệu	Accuracy
Chowdhury et al. [9]	ResNet-50	COVID Radiography	khoảng 90%
Narin et al. [11]	ResNet-50	2–3 lớp	98%*
Mahbod et al. [6]	EfficientNet	Đa nguồn	88.5%
Tahir et al. [12]	DenseNet	COVID + Normal	96.8%*
Đề tài này	EfficientNet- B5	VinBigData + COVID	91.76%

Các kết quả có dấu (*) thường thuộc bài toán ít lớp hơn nên không thể so sánh tuyệt đối. Tuy nhiên, việc đạt 91.76% trên bài toán 5 lớp cho thấy pipeline đề xuất có tính khả thi và có thể tiếp tục cải tiến để phục vụ thử nghiệm trong môi trường thực tế.

CHƯƠNG 6. KẾT QUẢ ĐẠT ĐƯỢC QUA ĐỢT THỰC TẬP

6.1 Kiến thức lý thuyết đã được củng cố

Thông qua quá trình thực hiện đề tài, sinh viên đã củng cố kiến thức về Deep Learning, CNN, Transfer Learning và các phương pháp đánh giá mô hình. Thay vì chỉ tiếp cận ở mức lý thuyết, sinh viên có cơ hội quan sát trực tiếp cách feature map được hình thành qua các lớp tích chập, cách Global Average Pooling rút gọn đặc trưng và cách Softmax chuyển logits thành xác suất dự đoán.

Đối với Transfer Learning, sinh viên hiểu rõ hơn lý do tại sao trọng số học từ ImageNet có thể tái sử dụng cho ảnh y khoa. Các đặc trưng thấp như cạnh, đường biên và texture vẫn có giá trị khi chuyển sang ảnh X-quang. Quá trình fine-tuning giúp mô hình thích nghi với đặc trưng bệnh lý cụ thể như vùng mờ phổi, tổn thương xơ hóa hoặc dấu hiệu viêm phổi.

6.2 Kỹ năng thực hành đã học hỏi được

Về mặt thực hành, sinh viên đã xây dựng được một pipeline Machine Learning tương đối đầy đủ: tải dữ liệu, lọc nhãn, chuẩn hóa dữ liệu, cân bằng lớp, thiết kế augmentation, huấn luyện, đánh giá và lưu checkpoint. Quá trình này giúp sinh viên hiểu rõ tầm quan trọng của dữ liệu trong bài toán AI y tế, đặc biệt là vấn đề mất cân bằng lớp và khác biệt miền dữ liệu.

Sinh viên cũng rèn luyện kỹ năng lập trình với PyTorch và thư viện timm. Các kỹ năng cụ thể gồm xây dựng Dataset và DataLoader tùy chỉnh, viết vòng lặp huấn luyện, sử dụng AMP, xử lý lỗi out-of-memory, lưu và nạp checkpoint, tính classification report và vẽ confusion matrix.

6.3 Sản phẩm và đóng góp cho đơn vị thực tập

Kết quả chính của đợt thực tập là một mô hình EfficientNet-B5 có khả năng phân loại 5 lớp bệnh phổi từ ảnh X-quang ngực với accuracy 91.76% trên tập kiểm định. Bên cạnh mô hình, sinh viên còn xây dựng pipeline xử lý dữ liệu và đánh giá, có thể tái sử dụng cho các thử nghiệm tiếp theo của bộ phận R&D.

Đóng góp của đề tài đối với đơn vị thực tập nằm ở việc cung cấp một baseline kỹ thuật cho hướng tích hợp AI vào hệ thống y khoa Diamond. Mặc dù chưa phải sản phẩm triển khai lâm sàng, kết quả thực nghiệm giúp công ty có thêm cơ sở để đánh giá khả năng phát triển module hỗ trợ chẩn đoán hình ảnh trong tương lai.

6.4 Bài học kinh nghiệm

Bài học quan trọng nhất là hiệu năng mô hình phụ thuộc mạnh vào chất lượng dữ liệu và quy trình tiền xử lý. Một mô hình mạnh như EfficientNet-B5 vẫn có thể cho kết quả không ổn định nếu nhận dữ liệu nhiễu, phân phối lớp lệch hoặc augmentation không phù hợp. Do đó, trước khi tối ưu kiến trúc, cần bảo đảm dữ liệu được chuẩn hóa và kiểm soát tốt.

Bên cạnh đó, sinh viên nhận thấy việc đánh giá mô hình y tế không thể chỉ dựa vào Accuracy. Confusion Matrix, Recall và F1-score theo từng lớp giúp phát hiện các lỗi có ý nghĩa lâm sàng, chẳng hạn mô hình bỏ sót bệnh hoặc nhầm bệnh nhẹ thành Normal. Đây là kinh nghiệm quan trọng khi phát triển các hệ thống AI có khả năng ứng dụng trong y tế.

CHƯƠNG 7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 Kết luận

Đề tài đã hoàn thành mục tiêu xây dựng hệ thống hỗ trợ chẩn đoán bệnh phổi trên ảnh X-quang ngực bằng mạng nơ-ron tích chập. Pipeline được triển khai từ bước chuẩn bị dữ liệu, huấn luyện EfficientNet-B5 đến đánh giá kết quả bằng các chỉ số chuẩn. Mô hình đạt accuracy 91.76% trên tập kiểm định 5 lớp, vượt mục tiêu tối thiểu 85% đặt ra ban đầu.

Kết quả thực nghiệm cho thấy Transfer Learning với EfficientNet-B5 là hướng tiếp cận phù hợp cho bài toán phân loại ảnh X-quang ngực trong điều kiện dữ liệu có giới hạn. Các kỹ thuật như undersampling, augmentation, MixUp, Label Smoothing, AdamW, AMP và TTA góp phần cải thiện độ ổn định và khả năng tổng quát hóa của mô hình.

7.2 Hạn chế

Hạn chế lớn nhất của đề tài là dữ liệu được thu thập từ các bộ dữ liệu công khai, chưa phản ánh đầy đủ điều kiện ảnh thực tế tại từng cơ sở y tế. Sự khác biệt về thiết bị chụp, quy trình chụp, độ phân giải và chất lượng ảnh có thể tạo ra domain shift khi mô hình được áp dụng ngoài môi trường thử nghiệm.

Ngoài ra, mô hình hiện mới dừng ở mức phân loại ảnh thành 5 lớp, chưa xác định vùng tổn thương cụ thể trên ảnh. Một số lớp như Fibrosis và Lung Opacity vẫn có mức nhầm lẫn nhất định do biểu hiện hình ảnh tương đồng. Điều này cho thấy mô hình cần được đánh giá thêm trên dữ liệu thực tế và có thể cần kết hợp thêm thông tin lâm sàng.

7.3 Hướng phát triển

Trong các hướng nghiên cứu tiếp theo, có thể mở rộng tập dữ liệu bằng ảnh từ nhiều bệnh viện và thiết bị chụp khác nhau nhằm giảm domain shift. Bên cạnh đó, mô hình có thể được thử nghiệm với các kiến trúc mới hơn như Vision Transformer hoặc Swin Transformer để khai thác tốt hơn quan hệ toàn cục trong ảnh X-quang [13, 14].

Một hướng phát triển quan trọng khác là bổ sung khả năng giải thích mô hình bằng Grad-CAM hoặc các kỹ thuật Explainable AI. Bản đồ nhiệt giúp bác sĩ quan sát vùng ảnh mà mô hình tập trung khi đưa ra dự đoán, từ đó tăng tính minh bạch và độ tin cậy của hệ thống. Về mặt triển khai, mô hình cần được đóng gói thành API ổn định, tích hợp kiểm tra chất lượng ảnh đầu vào và xây dựng cơ chế lưu trữ kết quả phù hợp với quy trình của hệ thống Diamond.

TÀI LIỆU

- [1] MaSoThue, “0318761246 - cÔng ty cỔ phẦn ehealth,” <https://masothue.com/0318761246-cong-ty-co-phan-ehealth>, 2026, truy cập ngày 05/06/2026.
- [2] P. Rajpurkar, E. Chen, O. Banerjee, and E. J. Topol, “Ai in health and medicine,” *Nature Medicine*, vol. 28, no. 1, pp. 31–38, 2022.
- [3] D. Shen, G. Wu, and H.-I. Suk, “Deep learning in medical image analysis,” *Annual Review of Biomedical Engineering*, vol. 19, pp. 221–248, 2021.
- [4] J. M. Johnson and T. M. Khoshgoftaar, “Survey on deep learning with class imbalance,” *Journal of Big Data*, vol. 6, no. 1, pp. 1–54, 2019.
- [5] M. Tan and Q. V. Le, “Efficientnet: Rethinking model scaling for convolutional neural networks,” in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019.
- [6] A. Mahbod, N. Saeedi, R. Ecker, and I. Ellinger, “Automatic covid-19 lung infection segmentation and measurement using efficientnet and multi-scale feature fusion,” *Diagnostics*, vol. 12, no. 3, p. 609, 2022.
- [7] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning and transfer learning for medical image analysis: A survey,” *IEEE Transactions on Medical Imaging*, 2022.
- [8] H. Zhang, M. Cisse, Y. N. Dauphin, and D. Lopez-Paz, “mixup: Beyond empirical risk minimization,” in *International Conference on Learning Representations (ICLR)*, 2018.
- [9] M. E. Chowdhury *et al.*, “Can ai help in screening viral and covid-19 pneumonia?” *IEEE Access*, vol. 8, pp. 132 665–132 676, 2021.
- [10] P. Rajpurkar, J. Irvin, K. Zhu, B. Yang, H. Mehta, T. Duan, D. Ding, A. Bagul, C. Langlotz, K. Shpanskaya *et al.*, “Chexnet: Radiologist-level pneumonia detection on chest x-rays with deep learning,” *arXiv preprint arXiv:1711.05225*, 2017.
- [11] A. Narin, C. Kaya, and Z. Pamuk, “Automatic detection of coronavirus disease (covid-19) using x-ray images and deep convolutional neural networks,” *Pattern Analysis and Applications*, vol. 24, no. 3, pp. 1207–1220, 2021.
- [12] A. M. Tahir *et al.*, “Covid-19 infection localization and severity grading from chest x-ray images,” *Computers in Biology and Medicine*, vol. 135, p. 104598, 2021.

- [13] A. Dosovitskiy *et al.*, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations (ICLR)*, 2021.
- [14] Z. Liu *et al.*, “Swin transformer: Hierarchical vision transformer using shifted windows,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 10 012–10 022.